

Table 1: 폐사체 수거 작업의 단계별 성능 개선 결과. 초기 OpenVLA 모델은 폐사 개체를 탐지하고 접근할 수 있었으나 파지에 실패하였다. DAgger를 적용하여 파지 능력을 회복하였으며, 이후 객체 물리 특성을 개선함으로써 최종적으로 94%의 작업 성공률을 달성하였다.

Stage	Key change	Grasp	Full task
Base	multi-view RGB, proprio	0/8	0%
OFT	action chunking	0/8	0%
Wrist depth	wrist (z-depth)	0/8	0%
DAgger	on-policy relabeling	7/8	0%
Firm-hold	friction, inertia $\uparrow$	12/16	75%
Thick capsule	grasp capsule $\uparrow$	17/18	94%

Table 2: 단독(solo) VLA의 죽은 병아리 pick-and-place 성공률 추이. 관측·구조 보강만으로는 grasp을 회복하지 못하나(1-2행), DAgger가 페루프 grasp 실행을 회복하고(3행), 시뮬레이션 객체를 물리적으로 graspable하게 만들면(4-5행) full-task 성공률이 0 $\rightarrow$ 94%에 도달한다. 모든 평가는 스크립트 매크로 없이 VLA 단독, 학습 분포(train-distribution) 조건, 단일 병아리 장면이다.

#	단계 (Stage)	핵심 변경 (Key change)	Grasp	Full-task
1	Base / OFT	multi-view RGB + proprio + action chunking	0/8	0/8
2	+ wrist depth	wrist 입력 슬롯 $\rightarrow$ z-depth	0/8	0/8
3	+ DAgger	on-policy 전문가 재라벨링	7/8	0/8
4	+ firm-hold	마찰 2.0 $\rightarrow$ 6.0, 관성 $5e-5 \rightarrow 4e-4$	12/16	12/16 (75%)
5	+ thick capsule	grasp 캡슐 0.013 $\rightarrow$ 0.018	17/18	17/18 (94%)

† 1행은 멀티뷰 / depth / affordance / 컨트롤러 재설계 등 grasp = 0인 모든 사전 시도의 대표값이다.

‡ 4-5행은 동일한 DAgger 정책(정책 고정)에서 객체 물리만 변경한 것이다. grasp 캡슐은 **alpha**=0이라 렌더 이미지가 byte-identical $\Rightarrow$ 동일 정책을 합당한 객체에서 측정한 결과이다.

§ 94% 런의 투하 정밀도: 중앙값 1.95 cm, 최대 4.93 cm, 전부 ≤ 5 cm, grasp $\rightarrow$ 안착 17/17 = 100%.

Table 3: 관측·구조 보강 ablation. 입력을 멀티뷰 RGB, wrist depth, proprioception, action chunking으로 확장해도 grasp을 회복하지 못한다. 능력 회복은 입력 보강이 아니라 on-policy 학습(DAgger)에서 비롯되었다.

방법 (Method)	입력 (Inputs)	Grasp	Full-task
Base (OpenVLA)	agentview RGB (1 $\times$)	0/8	0/8
OFT multi-view (2a)	agentview + wrist RGB, proprio, chunk	0/8	0/8
OFT + wrist depth (2b)	wrist 슬롯 $\rightarrow$ z-depth	0/8	0/8
grasp-affordance	얇고 긴 grasp 타깃 캡슐	0/8	0/8
+ DAgger	(동일 입력)	7-8/10	—

Table 4: 객체 물리 ablation (DAgger 정책 고정). 죽은 병아리의 마찰·관성과 grasp 캡슐 두께를 합리적 범위로 조정하면 full-task 성공률이 단조 증가한다. 시뮬레이션 manipulation이 객체의 마찰·관성·접촉 기하에 민감함을 보인다.

객체 설정	마찰	관성	캡슐 r	Full-task
slippery (원본 aff)	2.0	$5e-5$	0.013	9/16 (56%)
firm-hold	6.0	$4e-4$	0.013	12/16 (75%)
firm + thick	6.0	$4e-4$	0.018	17/18 (94%)

Table 5: 배포 변형 비교. 단독 VLA와 하이브리드(VLA navigation + 스크립트 매크로 grasp/운반) 시스템의 task 성공률. 학습된 핸드오프 트리거 (ResNet18, val AUC 0.986)는 시물 정보 없이 관측만으로 핸드오프를 결정한다.

시스템	NAV	Grasp + 운반	성공률
VLA solo (firm + thick)	VLA	VLA	17/18 (94%)
Hybrid (고정 핸드오프)	VLA	매크로	7/8 (87.5%)
Hybrid + 학습 트리거	VLA	매크로	8/8 (100%)
Postgrasp hybrid	VLA	매크로 운반	6/10 (60%)

Table 6: 진단 체인. 단독 VLA가 task를 풀기까지 식별·교정한 실패 모드와 근본 원인. 각 수정은 독립적으로 검증되었으며, 마지막 두 행(폐루프 실행, 객체 물리)이 0 → 94% 도약을 만들었다.

증상 (Symptom)	근본 원인 (Root cause)	수정 (Fix)	효과
로봇 정지(no-op)	평가 이미지 좌우 반전 ⇒ Y축 부호 반전	수집과 동일하게 상하 반전만 적용	동작 회복
약한 예측	thermal 해상도/순서 불일치 (OOD)	256에서 thermal 후 224 리사이즈	예측 강화
localization 8 cm	고정 BDDL + 정지 병아리 (평가 OOD)	학습 분포(랜덤 장면 + wander)로 평가	1 mm 도달
grasp 미실행	bang-bang 거친 액션 ⇒ fine grasp 불능	Dagger (on-policy 재라벨)	grasp 0 → 8/10
운반 중 슬립	객체 관성 작음 + 얇은 캡슐	firm-hold + thick capsule	full 0 → 94%

Table 7: 재현 가능한 작동 모델의 대규모 재평가($n = 50$, LIBERO 표준 trial 수). 움직이는 산닭 8마리 사이에서 정지한 폐사체 1마리를 골라 바구니에 투하하는 task를 50회 측정하였다. task 성공률 90.0%, 파지 성공률 92.0%이며, 파지 성공 시 바구니 중심까지의 투하 정밀도는 중앙값 1.34 cm로 전부 5 cm 이내에 안착하였다. 소표본($n = 18$, 83.3%) 대비 안정적으로 수렴한다.

지표 (Metric)	값 ($n = 50$)
Task 성공률	45/50 (90.0%)
Grasp 성공률	46/50 (92.0%)
투하 정밀도 — 중앙값	1.34 cm
투하 정밀도 — 평균	1.47 cm
투하 정밀도 — 최대	3.93 cm
바구니 중심 ≤ 5 cm	45/45 (100%)